

O processo de Ciência de Dados

Estudo de Caso - Credit Score

1. Introdução

Objetivo

O objetivo deste estudo de caso é aplicar técnicas de ciência de dados para analisar e prever scores de crédito. O score de crédito é uma medida utilizada por instituições financeiras para avaliar a probabilidade de um indivíduo pagar suas dívidas.

2. Carregamento e Visualização dos Dados

Importação das Bibliotecas

Primeiramente, importamos as bibliotecas necessárias para a análise dos dados.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

Carregamento dos Dados

Os dados são carregados de um arquivo CSV utilizando a biblioteca Pandas.

```
df = pd.read_csv('credit_score_data.csv')
df.head()
```

Análise Exploratória dos Dados

Analizamos as primeiras linhas do DataFrame para entender a estrutura dos dados.

```
print(df.info())
print(df.describe())
```

3. Limpeza e Preparação dos Dados

Tratamento de Valores Ausentes

Identificamos e tratamos valores ausentes no DataFrame.

```
df.isnull().sum()  
df = df.dropna()
```

Codificação de Variáveis Categóricas

Convertendo variáveis categóricas em numéricas usando técnicas como One-Hot Encoding.

```
df = pd.get_dummies(df, drop_first=True)
```

4. Análise Exploratória dos Dados

Análise Univariada

Analizamos a distribuição das variáveis individuais.

```
df['score'].hist()  
plt.show()
```

Análise Bivariada

Analizamos a relação entre duas variáveis.

```
sns.boxplot(x='income', y='score', data=df)  
plt.show()
```

5. Modelagem Preditiva

Divisão dos Dados

Dividimos os dados em conjuntos de treinamento e teste.

```
from sklearn.model_selection import train_test_split  
  
X = df.drop('score', axis=1)  
y = df['score']  
  
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,  
                                                    random_state=42)
```

Treinamento do Modelo

Treinamos um modelo de Regressão Linear nos dados.

```
from sklearn.linear_model import LinearRegression  
  
model = LinearRegression()  
model.fit(X_train, y_train)
```

Avaliação do Modelo

Avaliamos a performance do modelo utilizando métricas de erro.

```
from sklearn.metrics import mean_squared_error

predictions = model.predict(X_test)
mse = mean_squared_error(y_test, predictions)
print(f'Mean Squared Error: {mse}')
```

6. Exercícios

Exercício 1

Carregue os dados de um novo conjunto de dados de crédito e realize uma análise exploratória semelhante.

Exercício 2

Aplique uma técnica de imputação para tratar valores ausentes em um DataFrame.

Exercício 3

Experimente um modelo de árvore de decisão para prever scores de crédito e compare com a regressão linear.

8. Referências

- Documentação do Pandas
- Documentação do Scikit-learn
- Documentação do Matplotlib
- Documentação do Seaborn